Informe final - PrestaMatch

Grupo 19: Bertone, Ayala, Stoffel | Código: prestaMatch/main.py

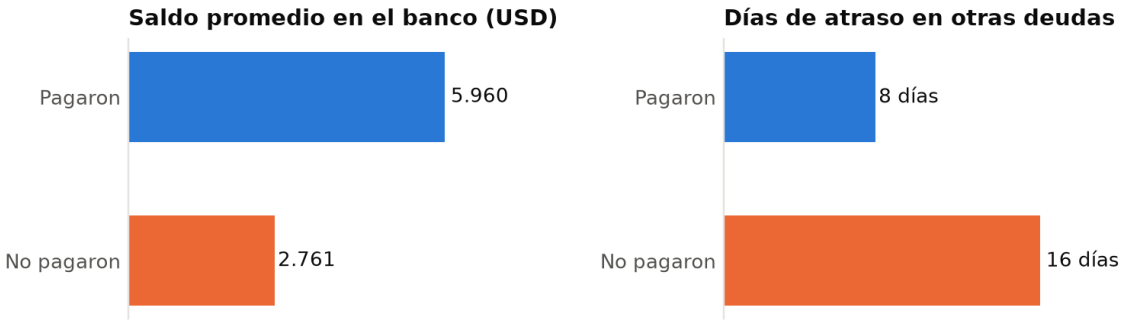
1. Cómo pensamos el problema

Lo primero que entendimos es que acá no gana el modelo que más acierta, sino el que **más plata deja**. Si alguien paga, ganamos los intereses (más o menos un 26% de lo prestado). Si no paga, perdemos todo el préstamo. O sea, un solo cliente que no paga se come lo que ganamos con unos 4 que sí pagan. Por eso armamos la solución en tres pasos:

- **Estimar la chance de que cada persona pague** (eso hace el modelo).
- **Calcular cuánto esperamos ganar por cada dólar que le prestamos.** Por ejemplo, con 90% de chance y 30% de interés ganamos 17 centavos por dólar; con 75% de chance perdemos plata, así que lo rechazamos.
- **Prestar a los que más rinden por dólar hasta gastar los 2 millones.** Lo pensamos como llenar una mochila con un límite de peso: conviene meter lo que más vale por kilo, no lo más caro. Si un préstamo no entra, pasamos al siguiente.

2. Qué encontramos en los datos

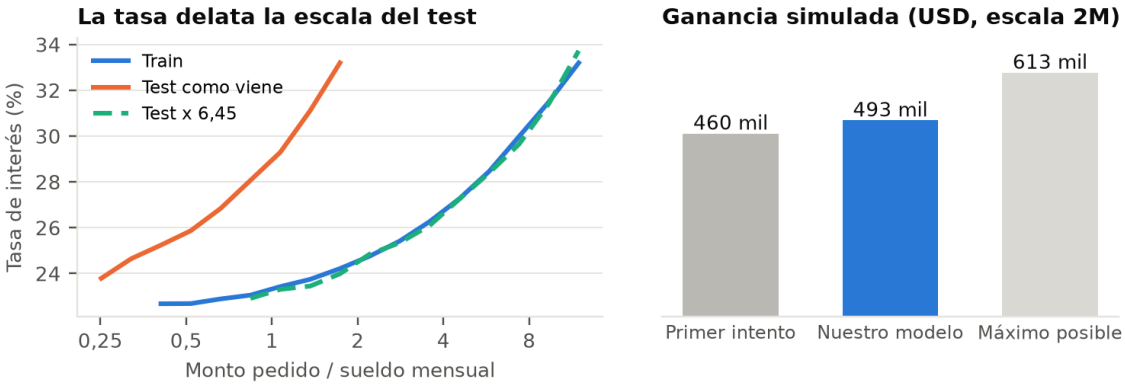
El historial del banco es lo que más dice de cada persona. Comparando a los que pagaron con los que no, la diferencia es enorme:



Además vimos que cada persona se comporta igual antes y después de pedir el préstamo. Es como su "forma de ser" con la plata. Por eso decidimos **usar los 24 meses completos** de cada cliente: un mes suelto es como una foto borrosa y muchos meses juntos dan una foto nítida. Probamos también usando solo los meses anteriores al pedido y dio prácticamente lo mismo, así que no estamos usando información del futuro. Con el historial armamos estas variables:

- **Saldo comparado con el sueldo.** Tener 3.000 USD ahorrados no es lo mismo si ganás 1.000 que si ganás 10.000. También miramos si los ahorros vienen subiendo o bajando.
- **Atraso habitual, sin contar los "picos".** A veces hay un mes suelto con un atraso altísimo. Es como un día de fiebre: no muestra cómo es la persona normalmente. Calculamos el atraso sin esos meses y, aparte, cuántos picos tuvo.

Los montos del test vienen achicados. Los préstamos del test son unas 6,45 veces más chicos que los de train. Nos dimos cuenta por la tasa de interés: la plataforma cobra más interés a quien pide mucho en relación a su sueldo, y en el test las tasas no cuadran con los montos. Si multiplicamos esos montos por 6,45, cuadran perfecto con train:



Por eso, antes de darle los datos al modelo, multiplicamos el monto del test por 6,45. Si no lo hacíamos, el modelo creía que todos eran préstamos chicos y seguros, y en nuestra simulación se perdían unos 67.000 USD. La ganancia la seguimos calculando con el monto real.

3. El modelo

Usamos **dos modelos y promediamos lo que dicen**, como pedir una segunda opinión. Uno es una **regresión logística**, que funciona como una planilla de puntos: cada dato suma o resta y el total se convierte en una chance de pago. El otro es **LightGBM**, que arma muchos árboles de preguntas de sí o no, y cada árbol nuevo corrige los errores de los anteriores. No balanceamos las clases porque necesitamos que, si el modelo dice "90%", sea 90% de verdad: ese número entra directo en la cuenta de plata.

4. Cómo comprobamos que funciona

Como no tenemos las respuestas del test, lo simulamos con train. Lo separamos en 5 partes, entrenamos con 4 y probamos con la que quedó afuera, rotando. Cuidamos que una misma persona nunca esté en las dos partes, porque en el test todos los clientes son nuevos. Después tomamos cada mes de train como si fuera enero, con un presupuesto que cubre el mismo 29% de lo pedido, y calculamos cuánta plata habríamos ganado (gráfico de la ganancia, en la página 1). El primer intento en el test real rinde todavía menos, porque no corregía los montos.

En Kaggle el modelo nuevo dio **143.000 USD** (antes teníamos 136.000). Kaggle muestra menos que nuestra simulación porque el ranking público calcula con una parte del test. Por la misma razón ese número tiene bastante suerte (podría haber caído entre unos 128.000 y 167.000), así que tomamos las decisiones con nuestra simulación y no con el ranking.

5. Lo que probamos y no funcionó

- **Usar solo los últimos 6 meses del banco** (nuestro primer intento): ordenaba peor a los clientes.
- **Usar el monto del test tal cual viene:** se pierde plata, como explicamos arriba.
- **Modelos más complicados** (otros tipos de árboles, logística con curvas y combinaciones): **todos dieron casi igual**. Eso nos mostró que lo que limitaba no era el modelo sino la información. Lo que más sumó fue armar mejores datos.
- **Ir cambiando cosas para subir en el ranking público:** lo descartamos, porque es acomodarse a una muestra chica y puede empeorar el resultado final.

6. Conclusión

Lo que más ayudó fue **entender bien los datos** (el historial completo y la corrección de los montos) y **decidir pensando en plata**, no en aciertos. Nuestra mayor duda es lo de los montos del test. Por eso subimos también una versión que no usa el monto (submission B) y elegimos las dos como entregas finales. La diferencia con el máximo posible es casi toda azar: personas con los mismos datos a veces pagan y a veces no.